

摘 要

饮食与每个人的生活息息相关，我国高校食堂后勤服务历经20余年的改革，在蓬勃发展的同时也面临着新的问题。过往针对高校食堂的研究存在着调研方法较为单一、数据来源较为主观的问题；而条件随机场模型主要应用于自然语言处理领域，未见于其他研究。基于此，本文提出一种新的研究视角，以上海财经大学为例，以条件随机场理论为基础，结合客观真实的学生群体就餐地点数据，研究学生群体在高校就餐地点的分布和转移，得到了给定饮食开销的条件下，学生群体选择就餐地点的条件概率分布列，以及不同就餐地点之间的转移概率矩阵，并探讨其平稳分布。最后，本文对上海财经大学食堂进行了相应的分析，也提出了本研究的不足和展望之处。

关键词： 条件随机场，食堂调研，LBFGS算法，条件概率

Abstract

Diet is closely intertwined with the life of every individual. The logistics services of university cafeterias have undergone more than 20 years of reform in China, flourishing while facing new challenges. Nevertheless, the previous research methods were relatively single and data sources were subjective. Besides, Conditional Random Field (CRF) models are primarily applied in the field of Natural Language Processing (NLP) and have not been seen in other studies. Therefore, this paper proposes a new research perspective. Taking Shanghai University of Finance and Economics as an example, based on the theory of Conditional Random Fields and combined with objective and authentic data on student dining locations, this study investigates the distribution and transition of student groups in dining locations on campus. It derives the conditional probability distribution of student group choices of dining locations given dietary expenses, as well as the transition probability matrix between different dining locations, and explores their steady-state distributions. Finally, this paper conducts a corresponding analysis of the cafeteria at Shanghai University of Finance and Economics, and also presents the shortcomings and prospects of this research.

Keywords: Conditional Random Field, Campus Cafeteria, LBFGS algorithm, Conditional Probability

目 录

摘 要.....	I
ABSTRACT	II
第 1 章 引言	1
1.1 研究背景及意义	1
1.1.1 高校食堂服务现状.....	1
1.1.2 高校食堂定价与学生饮食开销	2
1.1.3 本研究的目的和意义	2
1.2 国内外研究现状及文献综述.....	3
1.2.1 高校食堂调研现状.....	3
1.2.2 条件随机场理论研究现状.....	3
1.2.3 过往研究不足与本研究的补充价值	4
1.3 论文结构安排.....	5
1.3.1 研究问题	5
1.3.2 理论基础	5
1.3.3 数据来源	5
1.3.4 实证研究	5
1.3.5 研究总结	6
1.4 本文的主要贡献及不足	6
第 2 章 条件随机场理论与建模过程	7
2.1 上海财经大学简介	7
2.2 条件随机场模型建立与模型假设.....	8
2.2.1 概率无向图的建立.....	8
2.2.2 线性链条件随机场的建立.....	9
2.3 线性链条件随机场模型的参数估计方法.....	11
2.4 线性链条件随机场模型的参数估计方法.....	12
2.4.1 改进的迭代尺度法.....	12
2.4.2 拟牛顿法	13

第 3 章 实证研究	15
3.1 数据获取	15
3.1.1 问卷设计与调查方法	15
3.1.2 问卷数据有效性检验	16
3.1.3 样本画像与描述性统计分析	17
3.2 问卷数据清洗与预处理	19
3.2.1 数据集简介	19
3.2.2 数据预处理	20
3.3 条件随机场建模	21
3.3.1 确定特征函数	21
3.3.2 确定条件随机场模型参数化形式	21
3.3.3 基于L-BFGS算法的权重参数估计	21
3.4 模型结果实证分析	22
3.4.1 条件分布	22
3.4.2 转移概率矩阵	23
3.4.3 平稳分布	24
第 4 章 总结与展望	26
4.1 研究总结	26
4.1.1 本文的创新点	26
4.1.2 本文的局限	26
4.2 研究展望	27
参考文献	28
附 录	31
致 谢	32

插图

2.1	上海财经大学校园手绘地图	7
2.2	概率无向图示例	8
2.3	本研究的建立的概率无向图模型	9
2.4	线性链条件随机场例1.....	10
2.5	线性链条件随机场例2.....	10
2.6	本研究建立的条件随机场模型	10
3.1	样本画像统计	17
3.2	样本就餐情况统计	18
3.3	预测准确率随L2系数变化情况	22

表格

3.1	卡方独立性检验结果	19
3.2	数据和变量介绍	20
3.3	条件概率求解结果	22
3.4	转移概率求解结果	23
3.5	平稳分布求解结果	25

第一章 引言

1.1 研究背景及意义

“民以食为天”，饮食健康和食品安全与每个人的生活息息相关。随着人们生活水平的提高和生活方式的变化，人民的饮食结构也在不断更新，饮食品类也日益丰富。而在高校群体中，餐饮需要满足当代大学生的交往需求，体现高校的文化氛围，创造出优美、舒适的新型大学生饮食空间(刘全, 2008)。

1.1.1 高校食堂服务现状

高校后勤服务在高等学校中具有保障性地位(高庆, 2009)，后勤服务的质量关乎在校学生、教职工及其家属的生活体验。高校食堂作为高校后勤服务中的重要一环，其饭菜价格、口味、卫生、就餐环境等是衡量其服务质量的重要标准。学生群体每天都要进行饮食消费，提高学生群体的满意度，不仅是后勤管理者的责任，更是高校文化建设的关键条件。

1999年，我国开始积极推进高校后勤社会化改革¹，至今已有20余年²，我国高校师生的后勤条件得到了极高的改善。然而，目前高校食堂服务却依然出现备受关注的问題，例如食品安全、食品卫生、食品定价、食堂拥堵等：2023年6月，江西工业职业技术学院的“鼠头鸭脖”事件被全网关注。仅仅四个月后，华北理工大学又出现疑似“鼠头”异物³；“预制菜进校园”又一次引发了舆论漩涡。

因此，基于就餐群体——高校学生的视角，研究高校食堂的就餐情况，在当下依然十分必要。笔者在本科求学期间，对本校食堂十分熟悉，感情十分深厚，有着较为感性的认识。在结合本专业所学之后，一直想以一种新的视角研究笔者较为感兴趣的问题，藉此作为本论文研究起始，希望在毕业之际能为本校发展贡献绵薄之力。

¹<https://hq.lzu.edu.cn/hdupf/fil/201811/201811201542675927356819.pdf>

²https://www.gov.cn/gongbao/content/2000/content_60635.htm

³<https://mp.weixin.qq.com/s/U0LbXX6NDYxmeTLHeOdq1g>

1.1.2 高校食堂定价与学生饮食开销

根据中青网调查⁴，大学生的日常支出中有47%花费在饮食开销上；据腾讯教育联合麦可思在2020年末对大学生生活费的调查⁵，基本伙食费占据了大学生一半以上的每月开销。而高校食堂作为学生的主要就餐地点和支出去向，其饭菜价格受到学生的高度关注。政府有关部门为保护学生利益，对高校食堂做出限价规定(孙平生, 2011)，并给予大学生一定的财政补贴。然而，按照市场规律，物价上涨对高校管理者和食堂经营者带来较大的压力。高校食堂的定价标准，影响着校园稳定和高校的健康发展。

对于生活费不同档位或饮食开支占比不同的学生群体来说，其对饭菜价格的敏感性也应有所不同。而不同风格的高校餐厅，在菜品种类、饭菜价格、环境卫生等方面，也都会在学生群体中有着多样的评价。通过对比不同学生群体关注的因素，以及在给定某个因素下，不同食堂的学生就餐分布，可以对学生心目中各个食堂的性价比窥探一二。基于此，笔者对所就读的高校——上海财经大学，通过调研真实的学生就餐数据，研究各个食堂的学生群体中的性价比排序，从而为高校后勤部门提供较有参考的建议，以期提高高校后勤服务质量。

1.1.3 本研究的目的是和意义

正如前文所述，目前高校后勤服务仍然是我国高等教育中较为重要的一环，高校食堂作为后勤保障的关键角色，承担着校园稳定的责任，体现着校园文化的建设。而饮食开销作为大学生占比最大的支出去向，高校食堂的饭菜定价将会收到广泛的关注。目前高校的食品安全和食堂建设仍然存在着亟待改善的问题，偶尔会暴露出尚未解决的缺陷，因此本研究课题有着较为实际的现实意义。

基于此视角，本文以条件随机场（Conditional Random Field, CRF）相关理论为理论基础，以上海财经大学食堂为研究对象，通过调研学生的就餐情况，研究影响就餐选择的因素，以及学生群体反映出的食堂性价比排序，为高校食堂调研提供了一种新的研究思路，也为上海财经大学食堂进行了较为客观的研究和分析。

⁴https://mp.weixin.qq.com/s/_ZItMyMKtODQTSBauyLj4Q

⁵<https://mp.weixin.qq.com/s/vVxyJDXWmBblCPu-U6Q-IQ>

1.2 国内外研究现状及文献综述

1.2.1 高校食堂调研现状

近年来,针对高校食堂、后勤服务等研究文献较少,多数研究发表于往年。在研究问题方面,其多集中于社会科学调研问题等方面,例如满意度调查、服务质量调查等。在定性研究方面,多数通过问卷调研、访谈调研或文献资料汇总等方法,对高校食堂后勤的建设情况进行论述。在定量分析方面,较为常见的方法是主成分分析、因子分析、方差分析、回归分析等较为基础的统计学方法。

高庆 (2009)针对学生食堂经营问题,设计了调查问卷,采用因子分析和多元回归模型,从食堂产品感知、服务质量感知、就餐环境和就餐条件四个方面进行了公共满意度调查;丁震 & 朱禹桢 (2020)以湖南省高校大学生为研究对象,基于德尔菲法建立了影响食堂满意度的四分图评价指标;廖乾超 & 陈文雯 (2019)以湖南某大学为研究对象,设计调查问卷,从食堂产品、饮食消费环境两方面,分析学生饮食需求,研究影响大学生饮食消费特征的因素。

在海外研究中,Ng (2005)针对美国某大学食堂,以包括食品质量、服务质量、饭菜价格、便利性在内的22份评价指标,研究了学生顾客的满意度;Klassena et al. (2005)研究了学生满意度受到餐厅设置的影响;Adora & Estepa (2005)用改进的SERVWQUA量表,研究美国中西部大学学生饮食感知和满意度的关系;Lee et al. (2007)针对餐饮服务品牌问题,从就餐环境、员工能力、饭菜品质、价格四个维度研究了学生选择食堂的因素。

1.2.2 条件随机场理论研究现状

条件随机场模型是自然语言处理 (Natural Language Processing, NLP) 领域的重要研究方法之一,广泛应用于处理语言的词汇、实体、术语、句子与篇章结构(余本功 & 范招娣, 2020)。在词汇方面,CRF被主要应用于分词、词性标注、语义标注等技术。王照卫 (2022)基于融合特征方法提高了条件随机场在中文分词问题中的准确率;袁里驰 (2023)基于双向LSTM网络优化了CRF模型,提出了中文分词和词性标注的联合方法,在准确率上大幅领先于传统的隐马尔可夫模型;白如江 et al. (2017)使用条件随机场模型,对科技文献深层语义理解提

升了10%左右的精度值。

在实体与术语方面，有较多学者基于CRF或BiLSTM-CRF模型研究了汉语、俄语、韩语、泰语等不同语言的实体识别(Le et al., 2017; Mozharova & Loukachevitch, 2016; Na et al., 2019; 孙瑞娜, 2015; 王红斌 et al., 2019); 在其他研究领域如疾病命名实体识别(Lee et al., 2016; Wei et al., 2016)、影评人名识别(禚镇宇 et al., 2019)等，CRF及其改进模型也都有着较为优秀的表现。

在句子信息的识别与提取方面，CRF模型主要被用于因果关系提取(Qiu et al., 2017)、用户活动识别(Bertomeu-Motos et al., 2019)、句子类型提取(Chen et al., 2017)等。CRF模型可以通过语句分析识别出事件类型，或从结构化或非结构化的文本中提取关键信息，通过有监督或半监督学习对上下文关系、概念和事件进行捕捉。

另外，在篇章结构研究中，CRF模型可以梳理篇章结构，整合文章信息，这也是NLP领域的研究热点之一。

1.2.3 过往研究不足与本研究的补充价值

在高校食堂服务的研究方面，过往研究的不足有：（1）调研方法单一。多使用问卷调研、访谈调研、文献调研等方法。（2）数据较为主观，有一定的样本偏差。在问卷调研中，量表类题目往往会被受访人的主观因素干扰，且难以排除个体异质性的影响，较为主观的数据真实性也难以保证。（3）建模方法较为简单。常见的模型如回归分析（多元线性回归、logistic回归）、因子分析、主成分分析等往往受到数据统计分布的限制和一定的建模假设，因此模型也有较为不足之处。

在条件随机场模型的研究方面，过往研究的主要不足是：（1）CRF及其扩展模型缺乏系统规范的评价标准。（2）应用场景除自然语言处理外，少见与其他研究领域。（3）模型训练结果容易受到样本特征、数据量的影响。

基于此，本研究尝试以条件随机场理论为基础，以上海财经大学为例，通过实际客观的样本地点分布数据，研究高校食堂的性价比因素。本研究的主要价值和创新点在于：（1）引入新的模型方法，研究高校食堂满意度，为调研方法提供新的视角。（2）问卷数据无主观因素的影响，仅通过统计样本就餐地点的客观数据进行建模研究，无主观量表打分类题目，数据结果更加真实可信。（3）研究可拓展性强，可以结合更复杂的数据结构和CRF的拓展模型，得

到更为细致的结论。(4) 理论结合实践, 通过实际抽样调查数据, 为高校后勤提供研究范式, 后续可考虑研究落地, 更好地服务高校建设。

1.3 论文结构安排

1.3.1 研究问题

本文拟研究的问题是: 在给定协变量取值的条件下, 探究上海财经大学学生就餐地点的分布和转移。例如, 在给定饮食开销的情况下, 我们将研究学生不同食堂的就餐比例以及他们之间的转移情况, 即给定自变量下, 因变量的条件分布列、转移概率矩阵等。通过分析这些数据, 我们可以更深入地了解学生不同饮食开销水平下对食堂选择的偏好和行为, 从而更好地理解食堂的性价比排名。

1.3.2 理论基础

本文拟使用条件随机场理论进行研究。条件随机场理论常用于序列标注、自然语言处理等问题, 但其核心问题是为了求出给定条件下随机变量分布的条件概率, 参数估计方法是极大似然估计法, 具体的优化算法有改进的迭代尺度法、拟牛顿法等。本研究在建模过程中还作出了相应的模型假设, 详细的理论介绍与模型推导见本研究第二章。

1.3.3 数据来源

本研究建模使用的数据为笔者通过线下问卷调研得到的第一手数据。调查群体选择了具有代表性的上海财经大学学生; 抽样方法使用分层抽样法和滚雪球抽样法; 数据清洗后进行数据建模, 参数估计方法使用L-BFGS算法。

1.3.4 实证研究

本研究在实证研究部分遵循了如下研究顺序: 首先, 对调研数据进行问卷检验, 包括游程检验、卡方独立性检验等非参数检验方法, 验证样本的代表性和模型假设的合理性。其次, 进行描述性统计分析, 得到样本画像和初步结论; 然后, 导入数据训练模型得到参数估计结果, 从而得到给定学生饮食开销条件

下，不同食堂的就餐概率分布列；最后，得到学生在不同食堂之间的转移概率矩阵（与价格因素无关），并讨论其平稳分布。

1.3.5 研究总结

本研究对高校食堂调研提出了一种新的研究视角，也使用了客观真实的数据，能够对高校后勤建设提出较为合理的建议；同时也有一些不足和可待改善之处，在未来研究展望中加以讨论。

1.4 本文的主要贡献及不足

本研究在研究方法和视角上带来了新的思考和贡献，为高校食堂调研领域注入了新的活力和可能性。首先，本研究引入了条件随机场模型，这是一种在自然语言处理领域广泛应用的模型，但在学生就餐地点研究中尚未被充分利用。通过将其应用于该领域，本研究开拓了条件随机场模型的应用范围，为实际问题提供了新的思路和方法。同时，本研究的调研方法也体现了一定的创新，采用了分层抽样和滚雪球抽样等方法，以确保研究数据的客观性和可信度，为研究结果的准确性提供了坚实的保障。

然而，尽管本研究在研究中取得了一些进展，但仍然存在一些值得关注的局限性。首先，本研究的样本量较小，仅包括了约60名上海财经大学本科生，这可能限制了对整体群体的把握和理解。其次，调研时间较短，仅为两个星期，这可能无法充分捕捉到一些季节性、时间性的变化和影响因素，使得研究结果的稳定性和可靠性受到一定程度的影响。此外，本研究未能充分考虑个体之间的差异性，例如性别、年级等因素可能会对研究结果产生影响，这也是在未来研究中需要加以关注和深入探讨的问题之一。

未来的研究可以在以下几个方面进行拓展和深入探讨。首先，可以进一步扩大样本规模，增加不同学校和地区的样本，以提高研究结果的代表性和泛化能力。其次，可以延长调研时间，采用长期跟踪的研究设计，以更好地捕捉就餐行为的变化和发展趋势。此外，还可以加强对个体差异性的研究，探索不同群体之间就餐行为的差异及其影响因素。最后，可以进一步完善模型设计，改进模型设置，提高模型的准确性和稳定性，以更好地应对实际问题的挑战。通过这些努力，可以为高校食堂管理和提供更有效的决策支持和管理建议，促进高校食堂的改革和发展。

第二章 条件随机场理论与建模过程

2.1 上海财经大学简介

上海财经大学（Shanghai University of Finance and Economics），简称“上财”，主校区位于上海市杨浦区国定路777号，校内共设置有第一、第二、第三、第四餐厅4个食堂。根据上海财经大学学生联合会介绍¹，以下简要介绍四个食堂的信息。

第一餐厅也称“绿叶食堂”，位于国定路校区绿叶步行街，主要菜品有烧腊、点心、煲仔饭等；第二餐厅也称“清真食堂”，位于国定路校区情人坡附近，主要菜品有羊肉、面食、砂锅等清真民族风味美食；第三餐厅也称“新食堂”，位于武东路校区地铁站附近，有麻辣烫、水饺、铁板烧等菜品；第四餐厅也称“新园食堂”，位于武川路校区地铁站附近，主要有石锅拌饭、麻辣香锅等就餐窗口。四个食堂的详细位置如图2.1²即校园地图所示。



图 2.1: 上海财经大学校园手绘地图

由图2.1可以看到，四个食堂大致分布于寝室园区、教学楼、图书馆等场所附近，学生就餐较为便利。而它们各有特色，在学生群体中口碑多样、褒贬不

¹<https://mp.weixin.qq.com/s/F-v5Tvttyge47XCJcYIuMDQ>

²<https://mp.weixin.qq.com/s/tokARHaHG7TSwUnWzij1Cg>

一，就餐人流量也略有不同，学生群体选择就餐地点的原因也是千人千面，笔者的四年校园生活中，对其爱恨情仇也是五味杂陈。基于此，本文结合条件随机场理论，收集学生就餐的实际数据，对上财食堂的就餐情况展开研究。

2.2 条件随机场模型建立与模型假设

条件随机场是给定一组随机变量 X 的条件下，随机变量 Y 的条件概率分布模型，其特点是假设输出随机变量构成马尔可夫随机场（Markov Random Field），即概率无向图模型（Probabilistic Undirected Graphical Model），可以由无向图表示联合概率分布。

2.2.1 概率无向图的建立

图（Graph）是由结点（Node）及连接结点的边（Edge）组成的集合。结点和边分别记作 v 和 e ，其各自的集合分别记作 V 和 E ，图记作 $G = (V, E)$ 。无向图是指边没有方向的图。概率图模型是由图表示的概率分布。




图 2.2: 概率无向图示例

如图2.2所示，设有概率分布 $P(Y)$ ，由无向图 $G(V, E)$ 表示概率分布 $P(Y)$ ，在图 G 中，结点 v 表示一个随机变量 Y_v ；边 e 表示随机变量之间的依赖关系。若该图满足成对、局部或全局马尔可夫性，则称其为马尔可夫随机场，或概率无向图模型。

在本文中，我们想研究的实际问题是学生在上财四个食堂之间的就餐转移与分布，我们不妨以一天的就餐地点为一个图模型，设一日三餐的就餐地点为一组随机变量 $Y = \{Y_t^i\}(t = 1, 2, 3; i = 1, 2, \dots, n)$ ，其中 t 取1、2、3分别代表早餐、午餐、晚餐， i 是样本个体编号。则 Y_t^i 是一个离散型随机变量，其取值




图 2.3: 本研究建立的概率无向图模型

为 $\{1, 2, 3, 4, 5\}$ ，分别代表第 i 个个体在 t 时刻的就餐地点是新园食堂、新食堂、清真食堂、绿叶食堂或其他地点（例如外卖、外出就餐或未就餐等），那么我们就可以针对本文研究问题建立一个简单的图模型如图2.3所示，若其满足成对、局部或马尔可夫性，就可以是一个马尔可夫随机场。而关于这三条马尔可夫性，有如下定理介绍其关系：

定理 2.1 (Koller & Friedman, 2009)

成对马尔可夫性、局部马尔可夫性和全局马尔可夫性是等价的。

由定理2.1，我们不妨假设图 G 满足成对马尔可夫性（Pairwise Markov Property）：设 u 和 v 是无向图 G 中任意两个没有边连接的结点，结点 u 和 v 分别对应随机变量 Y_u 和 Y_v 。其他所有节点为 O ，对应的随机变量组是 Y_o 。成对马尔可夫性指给定随机变量组 Y_o 的条件下，随机变量 Y_u 和 Y_v 条件独立，即 $P(Y_u, Y_v | Y_o) = P(Y_u | Y_o)P(Y_v | Y_o)$ 。

在本文研究的图2.3结构中， Y_1 和 Y_3 分别仅与 Y_2 连接，而 Y_1 与 Y_3 不通，因此我们不妨做如下假设：

假设1：给定样本个体 i 的午餐就餐地点，其早餐和晚餐就餐地点条件独立，即 $P(Y_1^i, Y_3^i | Y_2^i) = P(Y_1^i | Y_2^i)P(Y_3^i | Y_2^i)$ 。

2.2.2 线性链条件随机场的建立

首先给出条件随机场的定义：设 X 与 Y 是随机变量， $P(Y|X)$ 是在给定 X 的条件下 Y 的条件概率分布，若随机变量 Y 构成一个由无向图 $G = (V, E)$ 表示的马尔可夫随机场，即 $P(Y_v | X, Y_w, w \neq v) = P(Y_v | X, Y_w, w \sim v)$ 对任一节点 v 成立，则称条件概率分布 $P(Y|X)$ 为条件随机场。其中 $w \sim v$ 表示在图 $G = (V, E)$ 中所有与结点 v 有边连接的结点 w ， $w \neq v$ 表示结点 v 以外的所有节点。

若有随机变量序列 $X = (X_1, X_2, \dots, X_n)$ ，以及 $Y = (Y_1, Y_2, \dots, Y_n)$ ，在给定随机变




图 2.4: 线性链条件随机场例1




图 2.5: 线性链条件随机场例2

量序列 X 的条件下，随机变量 Y 的条件概率分布 $P(Y|X)$ 构成条件随机场，则称其为线性链条件随机场（Linear Chain Conditional Random Field）。现实中，一般假设 X 和 Y 有相同的图结构，如图2.4³、图2.5⁴所示。在本文的研究中，我们关注




图 2.6: 本研究建立的条件随机场模型

的问题是饭菜价格对学生就餐地点的影响，因此不妨给定 X 为表征经济能力的变量，学生每日饮食开销，取值0、1、2分别代表30元及以下、30-60元、60元及以上。则本文的条件随机场结构如图2.6所示。

然而对于不同的研究个体，价格因素对其就餐地点的选择可能并不会会有相同的影响，往往会受到个体异质性的干扰，例如性别、年龄带来的不可观测、不可解释的因素。为简化模型参数和建模难度，我们作出如下假设：

假设2：样本个体间具有同质性，即 $P(Y_i^i|X_i)$ 仅与 X 有关而与 i 无关。

³<https://www.cnblogs.com/pinard/p/7048333.html>

⁴<https://www.infoq.cn/article/q6jwjrhf0rbemoqi6mr>

2.3 线性链条件随机场模型的参数估计方法

由如下定理2.2，概率无向图模型的联合分布可以表示为最大团势函数乘积的形式：

定理 2.2 Hammersley-Clifford定理(Hammersley & Clifford, 1963)

概率无向图模型的联合概率分布 $P(Y)$ 可以表示为如下形式：

$$P(Y) = \frac{1}{Z} \prod_C \Psi_C(Y_C)$$

$$Z = \sum_Y \prod_C \Psi_C(Y_C)$$

其中， C 是无向图的最大团， Y_C 是 C 的结点对应的随机变量， $\Psi_C(Y_C)$ 是 C 上定义的严格正函数，乘积是在无向图所有的最大团上进行的。

而在线性链条件随机场 $P(Y|X)$ 中，在给定 X 取值为 x 的条件下， Y 取值为 y 的条件概率具有如下形式：

$$P(Y = y|X = x) = \frac{1}{Z(x)} \exp \left(\sum_{i,l} \mu_l s_l(y_i, x, i) + \sum_{i,k} \lambda_k t_k(y_{i-1}, y_i, x, i) \right) \quad (2.1)$$

式2.1中，

$$Z(x) = \sum_y \exp \left(\sum_{i,l} \mu_l s_l(y_i, x, i) + \sum_{i,k} \lambda_k t_k(y_{i-1}, y_i, x, i) \right) \quad (2.2)$$

式2.2中， s_l 和 t_k 都是特征函数，分别定义在结点和边上，称为转移特征函数和状态特征函数，取值为1或0，分别有 l 个和 k 个，需要建模时主观定义； μ 和 λ 分别为特征函数对应的权值，也是模型中的待估计参数，能够完全决定条件随机场。 $Z(X)$ 为归一化因子，保证概率值在 $[0,1]$ 范围内，且 Y 各个取值的概率和为1。在后续的实证研究中，本文将详细阐述特征函数的具体形式。

条件随机场也可以由简化形式表示，即将权值参数和特征函数统一表示，得到下式：

$$P(Y = y|X = x) = \frac{1}{Z(x)} \exp \sum_{k=1}^K \omega_k f_k(y, x) \quad (2.3)$$

其中， $Z(x)$ 仍为对 y 求指数权重得分之和的归一化因子。而若有 K_1 个转移特征和 K_2 个状态特征，记 $K = K_1 + K_2$ ，则可以将特征函数统一表示为

$$f_k(y_{i-1}, y_i, x, i) = \begin{cases} t_k(y_{i-1}, y_i, x, i), k = 1, 2, \dots, K_1 \\ s_l(y_i, x, i), k = K_1 + l; l = 1, 2, \dots, K_2 \end{cases}$$

再对位置 i 求和，便可得到式2.3中的 $f_k(y, x)$ ，即 $f_k(y, x) = \sum_{i=1}^n f_k(y_{i-1}, y_i, x, i)$, $k = 1, 2, \dots, K$ 同时可以将特征函数的权值统一表示为 w_k ，即

$$w_k = \begin{cases} \lambda_k, k = 1, 2, \dots, K_1 \\ \mu_l, k = K_1 + l; l = 1, 2, \dots, K_2 \end{cases}$$

这样我们就得到了条件随机场的简化形式，以便之后阐述其参数估计方法。

2.4 线性链条件随机场模型的参数估计方法

条件随机场模型的学习方法包括极大似然估计和正则化的极大似然估计，极大似然估计的基本原理是求出使得对数似然函数达到极大值的参数估计量。对于条件随机场模型，若已知训练集，可以得到样本经验概率分布 $\tilde{P}(X, Y)$ ，则可以得到训练数据的对数似然函数(茆诗松 et al., 2019):

$$L(w) = L_{\tilde{P}}(P_w) = \log \prod_{x,y} P_w(y|x)^{\tilde{P}(x,y)} = \sum_{x,y} \tilde{P}(x,y) \log P_w(y|x)$$

再由条件随机场的简化形式式2.3，可以得到其对数似然函数为

$$L(w) = \sum_{j=1}^N \sum_{k=1}^K w_k f_k(y_j, x_j) - \sum_{j=1}^N \log Z_w(x_j)$$

具体的优化实现算法有改进的迭代尺度法IIS、拟牛顿法等，参照李航(2019)的《统计学习方法》教材和Nocedal & Wright (2006)的《数值优化》教材，介绍算法如下。

2.4.1 改进的迭代尺度法

输入：特征函数 $f_k(y, x)$ ；经验分布 $\tilde{P}(x, y)$ ；

输出：最优参数估计值 $\hat{w}$ ；模型 $P_{\hat{w}}$ 。

- (1) 对 $k=1, 2, \dots, K$ ，赋初值 $w_k = 0$ ；
- (2) 对 $k=1, 2, \dots, K$ ，令 δ_k 是方程

$$\sum_{x,y} \tilde{P}(x) P(y|x) \sum_i f_k(y_{i-1}, y_i, x, i) \exp(\delta_k T(x, y)) = E_{\tilde{P}}(w_k)$$

的解。其中 $E_{\tilde{P}}(w_k)$ 是特征函数 f_k 关于经验分布 $\tilde{P}(X, Y)$ 的数学期望； $T(x, y)$ 是数据 (x, y) 中出现所有特征数的总和。

(3) 更新 w_k 的值： $w_k \leftarrow w_k + \delta_k$

(4) 若不是所有的 w_k 都收敛，则重复 (2) (3) 步，否则算法停止，得到参数估计值 $\hat{w}_k$ 。

式中特征数 $T(x, y)$ 对不同的样本数据取值可能不同，为处理该问题，衍生出了算法 S ，即定义了足够大的常数 S ，构造松弛特征，并对更新方程作出相应调整；而若 S 取值过大，迭代时增量也会变大，算法收敛的速度减慢，因此又衍生出了算法 T ，即对每个观测序列 x 计算其特征总数最大值，记为 T ，再对更新方程做出相应调整，利用牛顿法可以求得每步迭代的增量 δ_k 。

2.4.2 拟牛顿法

对于条件随机场模型，其优化的目标函数是

$$\min_w f(w) = \sum_x \tilde{P}(x) \log \sum_y \exp \left(\sum_{i=1}^n w_i f_i(x, y) \right) - \sum_{x, y} \tilde{P}(x, y) \sum_{i=1}^n w_i f_i(x, y)$$

其梯度函数由下式给出

$$g(w) = \sum_{x, y} \tilde{P}(x) P_w(y|x) f(x, y) - E_{\tilde{P}}[f(x, y)]$$

算法如下：

输入：特征函数 $f_k(y, x)$ ；经验分布 $\tilde{P}(x, y)$ ；

输出：最优参数估计值 $\hat{w}$ ；模型 $P_{\hat{w}}$ 。

- (1) 选定初始点 $w^{(0)}$ ，取 $\mathbf{B}_0$ 为正定对称矩阵，置 $k = 0$ 。
- (2) 计算 $g_k = g(w^{(k)})$ 。若 $g_k = 0$ ，则停止计算；否则转3。
- (3) 由 $\mathbf{B}_k p_k = -g_k$ 求出 p_k 。
- (4) 一维搜索：求 λ_k 使得

$$f(w^{(k)} + \lambda_k p_k) = \min_{\lambda \geq 0} f(w^{(k)} + \lambda p_k)$$

- (5) 置 $w^{(k+1)} = w^{(k)} + \lambda_k p_k$ 。

- (6) 计算 $g_{k+1} = g(w^{(k+1)})$ ，若 $g_{k+1} = 0$ 则停止计算，否则按下式求出 $\mathbf{B}_{k+1}$ ：

$$\mathbf{B}_{k+1} = \mathbf{B}_k + \frac{y_k y_k^T}{y_k^T \delta_k} - \frac{\mathbf{B}_k \delta_k \delta_k^T \mathbf{B}_k}{\delta_k^T \mathbf{B}_k \delta_k}$$

其中, $y_k = g_{k+1} - g_k$, $\delta_k = w^{k+1} - w^k$

(7) 置 $k = k + 1$, 转 (2)。

然而, 该方法需要每次保存迭代的历史值, 将占用较大的内存负担。L-BFGS算法则针对该缺陷进行改进, 在每次迭代时只使用最近 m 个历史值, 从而减小内存负担。

第三章 实证研究

3.1 数据获取

3.1.1 问卷设计与调查方法

3.1.1.1 问卷设计

除必要的保密声明及问候语外，根据需要的变量和数据类型，本研究设置的问卷题目汇总见附录。

3.1.1.2 调查过程

在本节，我们汇报调查方案和过程如下。

(1) 抽样调查方法：分层抽样法、滚雪球抽样法。

根据冯士雍 (1995)的教材《抽样调查理论与方法》，分层抽样法是将总体分成互不相交的子群体，再从每个子群体中简单随机抽样获得样本的方法，能够获得较为有代表性的样本群体；据Biernacki & Waldorf (1981)的介绍，滚雪球抽样法是一种基于参与者推荐的方法，研究者首先选择一些种子参与者，然后通过这些参与者的推荐，逐步扩大样本规模，这种方法能够接触到更多的潜在参与者。然而滚雪球抽样法也存在样本不够随机，存在偏倚的问题，我们在后续调查过程中，依据其指出的改进方法进行改进。

(2) 调查时间：2023年12月10日-2023年12月24日。

(3) 调查群体：上海财经大学学生。

(4) 调查过程：

首先，划定新园食堂、新食堂、清真食堂、绿叶食堂为一层抽样框，在每个食堂进行简单随机抽样，询问受访者是否愿意参加之后约两周的就餐调研，若有受访意愿则邀请其加入受访者微信群，至此完成分层抽样。

其次，询问受访者是否有熟识且有意愿参与调查的同学，邀请其参与调查，作为样本群体。这样在滚雪球抽样中，我们使用了多个独立的种子参与者，可以降低滚雪球抽样法有可能带来的样本偏倚。

因本文研究所需的时间序列数据的时间单位为一日三餐，需要得到大量样本个体的一日三餐的调研数据。为尽量避免个体异质性的影响，我们选定样本

群体，并登记个人信息后，对其接下来 N 天就餐情况展开跟踪调研：在每日8:00-10:00、11:00-13:00、17:00-20:00分别发放三次问卷，每次的调研问卷仅有两道题目（就餐地点、就餐原因），这样可以最大程度地避免因题目冗长造成的无效回答较多的问题。

在调查结束后，将不同个体的时序数据合并到一天之内，即将不同个体14天的数据视作同一天内大量样本个体的数据，从而简化数据结构，降低模型复杂度。

（5）调查结果

本次调查最终确定的样本群体有60余名上海财经大学学生；在调查的14天内，每日平均有40余人填写问卷；整个调查期间的40余份问卷中，完成率为100%的有3人，完成率在90%以上的有17人，完成率高于80%的有45人；合并数据后，缺失值约占15%左右，样本群体作答情况较好。

3.1.2 问卷数据有效性检验

本次调研的问卷无量表型题目，因此无需进行信度检验、效度检验，只需进行问卷数据的随机性检验，从而确保问卷数据具有一定的随机性和代表性，这里我们使用游程检验（Run Test）。

根据王星 (2014)教授的教材《非参数统计（第2版）》，随游程检验能够检验序列中的数据出现是否与顺序无关。在一个二元0/1序列中，一个由0或1连续构成的串称为一个游程。可以想到，一个序列中的游程数过少，则数据往往呈现集群趋势；反之若游程数过多，则数据易呈现交替趋势。因此，当一个序列的游程数较为适中时，才可以认为该序列数据是随机出现的。具体的显著性检验临界值由数据序列长度、游程个数和长度确定，在实际检验时，可以根据教材中提供的Run-Test游程检验表查询，也可调用开源的第三方统计分析库（例如python的statsmodel），自动计算 p 值。

本次检验的变量为二分类变量“性别”，取值为1或2。由于调研群体固定，因此我们仅检验有效答案最多的12月13日午餐时刻收集的问卷数据，共100条有效数据。

建立假设如下：

H_0 ：问卷数据不是随机的 vs H_1 ：问卷数据是随机的

调用python的第三方库statsmodels中的runtest_1samp函数¹，进行游程检验，检验结果的t值约为1.983，p值约为0.047，在5%的显著性水平下拒绝原假设，因此我们认为问卷数据是随机的，即样本具有随机性。

3.1.3 样本画像与描述性统计分析

接下来我们对样本进行画像统计、描述性统计分析及样本特征相关性检验。其中对样本的性别、年级、学院及就餐开销分布，我们用12月13日午餐问卷数据进行分析；三餐就餐地点和就餐原因我们用12月13日全天的3份问卷数据分别分析。

3.1.3.1 样本画像




图 3.1: 样本画像统计

绘制样本人群关于年级、性别、学院以及饮食开销的柱形图如图3.1所示。样本人群在年级、性别的分布上大致相当，其中大三、大四高年级本科生较多，女生比男生略多；大部分同学的每日饮食开销集中于30元至60元，消费水平较

¹https://www.statsmodels.org/stable/generated/statsmodels.sandbox.stats.runs.runtest_1samp.html#statsmodels.sandbox.stats.runs.runtest_1samp

为中等，只有约20%的同学每日饮食开销会超过60元；从学院分布上看，统计与管理学院的同学占据了样本人群的1/5，其次是信息管理与工程学院，来自法学院、人文学院、外国语学院、数学学院的同学较少。

3.1.3.2 样本就餐情况统计

关于就餐地点及选择该地点的原因，分别绘制早、午、晚三餐数据的分系列百分比柱形图。




图 3.2: 样本就餐情况统计

如图3.2所示，可以发现：从就餐地点上看，样本人群常去新园食堂、新食堂就餐，而清真食堂和绿叶食堂就餐人数较少；外卖就餐也占比较大，尤其是晚饭时刻；有较多同学不吃早饭，这可能是由于大学生作息较晚²、或早起上课较为匆忙所致³；在就餐地点选择原因方面，除了未就餐人群之外，“就餐方便”是其他样本人群选择就餐地点最为普遍的原因，这些食堂都分布在寝室园区附近，原因较为合理；其次，“饭菜较为可口”和“饭菜卫生”也是样本人群较为关心的原因。

²<https://mp.weixin.qq.com/s/qEUppoQ4hxIrsyRdBOim0A>

³<https://mp.weixin.qq.com/s/2otW6c5nSUdytkMKfi-i5w>

3.1.3.3 样本特征相关性检验

为检验个体异质性，我们将变量“就餐地点”、“就餐原因”和变量“性别”、“年级”进行定类变量的相关性检验，希望得出“样本个体的就餐地点及其选择该地点的原因与样本个体的性别、年级无关”的结论，检验方法使用卡方独立性检验（Chi-Squared Test）。

建立假设如下：

$H0$ ：变量A与B是独立的 *vs* $H1$ ：变量A与B是相关的

这里的变量A是“就餐地点”或“就餐原因”，变量B是“性别”或“年级”，共进行 $2 \times 2 = 4$ 组卡方独立性检验，调用python的第三方库scipy中的chi2.contingency函数进行检验⁴。

表 3.1: 卡方独立性检验结果

检验组别	卡方统计量	p值	自由度	检验结论
年级×地点	26.26	0.158	20	不拒绝原假设
年级×原因	19.18	0.510	20	不拒绝原假设
性别×地点	20.10	0.001	5	在1%的显著性水平下，拒绝原假设
性别×原因	4.44	0.489	5	

检验结果如表3.1所示，结果显示：就餐地点、选择原因和样本人群的年级无相关关系，选择原因和样本人群的性别也不相关；但就餐地点和性别之间却在1%的显著性水平下拒绝了两变量独立的原假设，说明不同性别偏好的就餐地点可能会有所不同。后续深入研究若能得到更大体量的数据集，可以考虑分男、女两性别数据分别建模分析。

总体来看，为了降低后续模型复杂度，我们仍可以忽略个体异质性，即认为样本个体的就餐地点及其选择该地点的原因与样本个体的性别、年级无关，因此前述假设2的合理性得以证明。

3.2 问卷数据清洗与预处理

3.2.1 数据集简介

接下来进行数据清洗与合并，并进行数据预处理。为降低变量维度，我们忽略时间差异和样本个体差异，将调查群体在12月13日至12月24日12天内三餐

⁴https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.chi2_contingency.html

时刻填写的36份问卷数据合并，统一视作不同样本个体在一天内三餐的就餐数据，共得到539条数据，再取“三餐地点”和“每日饮食开销”四个维度的信息，进行数据编码，汇总如表3.2所示。

表 3.2: 数据和变量介绍

变量名称	变量含义	变量取值	数据类型	编码规则
pos1	早餐地点	{1,2,3,4,5}	定类数据	1: 新园食堂; 2: 新食堂;
pos2	午餐地点	{1,2,3,4,5}	定类数据	3: 清真食堂; 4: 绿叶食堂;
pos3	晚餐地点	{1,2,3,4,5}	定类数据	5: 外卖
price	每日饮食开销	{0,1,2}	定序数据	0: 30元以下; 1: 30-60元; 2: 60元以上

3.2.2 数据预处理

在数据的合并过程中，由于并非所有样本人群都坚持填写完14天的40余份问卷，或并非每天都有三餐就餐，会出现不吃早饭、晚饭等情况，因此原始数据集中的pos、price变量会有部分缺失值，统计pos1、pos2、pos3、price四个变量的缺失率分别为：11.96%、14.67%、13.54%、13.77%。我们采用如下方法处理缺失值：

- (1) 若一天内缺失两次及以上就餐地点数据，则直接删除该行数据；
- (2) 对price变量缺失值，按照描述性统计结果，0、1、2取值以3：5：2的比例填充；
- (3) 对pos变量缺失值，按照调查149位上海财经大学学生“最常去的食堂”结果，以取值1、2、3、4、5分别占比28.19%、16.78%、42.28%、12.08%、0.67%的比例填充⁵。

填充缺失值后，设置在python中调用pandas库的sample函数⁶，设置随机种子为学号，按行随机打乱样本顺序后，划分训练集：测试集样本容量比例约为9：

⁵该填充比例由预调查数据确定<https://www.wjx.cn/wjx/activitystat/verifyreportpassword.aspx?viewtype=1&activity=259564141&type=1>，密码1234

⁶<https://pandas.pydata.org/pandas-docs/stable/reference/api/pandas.DataFrame.sample.html#pandas.DataFrame.sample>

1, 进行后续数据建模。

3.3 条件随机场建模

3.3.1 确定特征函数

在本文的研究问题中, 为简化模型参数, 降低模型复杂度, 我们仅设置状态特征函数, 忽略转移特征函数; 且在设置状态特征函数时忽略结点位置的因素, 即认为三个结点的状态特征函数具有相同的参数。对每个结点的取值情况, 设置二值状态特征函数如下:

$$S_l(Y_j, x_i, j) = \begin{cases} 1, Y_j = y_l \\ 0, Y_j \neq y_l \end{cases}, l = 1, 2, 3, 4, 5; j = 1, 2, 3$$

该函数表示: 在给定 X 取值为 x_i (x_i 共有0, 1, 2三种取值) 时, 若某节点 Y_j 取值为 y_l (j 取值有1, 2, 3三种, 即三个节点 Y_j ; y_l 共有1, 2, 3, 4, 5五种取值), 则该节点的状态特征函数 S_l 赋值为1, 否则为0, 每个节点都有5个状态特征函数。

3.3.2 确定条件随机场模型参数化形式

由于本研究未考虑转移特征函数, 因此可简化本模型的参数化形式为:

$$P(Y = y_l | X = x_i) = \frac{1}{Z(x)} \exp \left(\sum_j w_l S_l(Y_j, x_i, j) \right) \quad (3.1)$$

式3.1表示: 给定 X 取值 x_i 的条件下, Y 取值为 y_l 的条件概率, 该概率与节点位置无关。其中, $Z(X)$ 仍然为归一化因子, 即对 Y 的取值指数求和, 使得概率值计算落入 $[0,1]$ 区间内, w_l 为待估参数。

3.3.3 基于L-BFGS算法的权重参数估计

调用python第三方库sklearn中的crfsuite函数⁷, 建立CRF模型。在函数的参数设置上, 选择LBFGS算法、迭代次数100次及正则化系数, 进行参数估计。在模型训练时, 为避免过拟合导致泛化能力减弱, 我们对目标函数施加L2正则化惩罚。为选择必要的L2正则化系数, 我们采用验证集10折交叉验证的方法, 指标为预测准确率。

⁷<https://sklearn-crfsuite.readthedocs.io/en/latest/api.html>

图3.3汇报了预测准确率随L2正则化系数变化的情况。




图 3.3: 预测准确率随L2系数变化情况

可以看到，交叉验证的预测准确率约在85%~88%之间，而当超参数L2的正则化系数取4时，验证集有着最高的预测准确率，约89%。因此选择L2正则化系数为4进行训练，最终全样本预测准确率为92.74%，模型拟合效果较好。

3.4 模型结果实证分析

3.4.1 条件分布

将模型训练结果整理汇总，得到了给定每日饮食开销 X 取值时，学生去各个食堂 y_i 就餐的条件概率分布列如表3.3所示。通过横向、纵向分析，我们可以得出如下结论：

表 3.3: 条件概率求解结果

X/Y	新园食堂	新食堂	清真食堂	绿叶食堂	外卖
30元以下	0.29	0.22	0.23	0.16	0.10
30元-60元	0.22	0.16	0.18	0.17	0.26
60元以上	0.20	0.19	0.20	0.11	0.31

- (1) 选择新园食堂就餐和外卖就餐的群体，与其每日饮食开销的相关性较

为明显：每日饮食开销在30元以下的同学，有约30%的概率选择去新园食堂就餐，而仅有10%的概率选择外卖；每日开销在60元的同学选择外卖就餐的概率则明显高于其他两组。这与我们的日常认知较为相符，外卖餐饮动辄20元起送的服务、人均30元以上的消费的确需要较高的饮食开销才能承担。

(2) 新园食堂的就餐性价比位列四个食堂首位，不同群体的就餐概率均超过了平均概率1/5。通过与学生群体调研得知，新园食堂就餐环境优美、量价实惠，能够吸引较多学生就餐；而绿叶食堂的就餐性价比居于末位，大部分同学在该处的就餐概率在17%左右。甚至对于高饮食消费群体来说，仅有11%的概率选择绿叶食堂。通过调研学生群体反馈，较多同学认为绿叶食堂口味不佳、量价不均、卫生问题是其较明显的不足之处。

(3) 清真食堂的性价比居中，不同群体的就餐概率均在20%左右，分布较为均衡，这可能与其独特的民族风味较能吸引就餐群体有关。

(4) 对于不同消费价位的就餐群体来说，就餐地点性价比排序为：

低消费：新园食堂>清真食堂>新食堂>绿叶食堂>外卖；

中消费：外卖>新食堂>清真食堂>绿叶食堂>新食堂；

高消费：外卖>新园食堂=清真食堂>新食堂>绿叶食堂。

3.4.2 转移概率矩阵

得到条件分布列后，我们相当于仅仅研究了每个节点静态的状态特征分布是怎样的。而为了分析各个就餐地点之间动态的转移情况，我们可以采用离散马尔可夫过程的转移概率矩阵来分析。在模型训练过程中，函数参数选择了自动添加转移特征，因此我们将参数训练结果整理后，得到了样本分布的转移概率矩阵如表3.4所示。该转移概率矩阵与 X 取值无关，而仅与上一状态的地点取值 y_i 和下一地点取值 y_j 有关。

表 3.4: 转移概率求解结果

y_i/y_j	新园食堂	新食堂	清真食堂	绿叶食堂	外卖
新园食堂	0.29	0.18	0.18	0.15	0.20
新食堂	0.22	0.24	0.18	0.16	0.20
清真食堂	0.22	0.19	0.20	0.17	0.22
绿叶食堂	0.21	0.19	0.20	0.21	0.18
外卖	0.16	0.19	0.20	0.18	0.27

分析该转移概率矩阵，可以得到如下结论：

(1) 从对角线元素来看, 新园食堂和外卖就餐的“用户粘性”较高, 上一次就餐为该地点的学生群体, 下一次就餐地点仍有约30%的概率选择该地点。

(2) 从非对角元素看, 上一次就餐为新园食堂的群体, 下一次就餐约50%仍然会选择新园食堂或外卖, 而选择去其他三个食堂的转移概率较低, 尤其是转移到绿叶食堂的概率, 仅有15%, 这可能与两个食堂相距较远, 位于校园东西两侧有关。

(3) 新食堂和绿叶食堂的转入率较低, 除上一次就餐该地点的人群外, 从其他地点转移过来的概率均小于20%, 绿叶食堂尤甚。这可能与地理位置、饭菜吸引力较弱有关。

3.4.3 平稳分布

得到转移概率矩阵后, 一个很自然的研究问题就是研究其平稳分布。在Ross (2019)的教材中, 关于马氏链平稳分布的存在性有如下定理:

定理 3.1 埃尔戈德定理

在不可约非周期的马氏链中, 存在且唯一的平稳分布。

由定理3.1, 我们可以判断, 在上一节得到的转移概率矩阵中, 容易看出y的5个状态空间是互通的, 即所有状态同属一类, 该马氏链不可约; 对角线元素非0说明所有状态可以以非0的概率, 经过1步转移回到自身状态, 即周期为1, 因此该马氏链非周期。因此, 只需求解平稳方程组

$$\begin{cases} \pi_j = \sum_i \pi_i p_{ij} \\ \sum_j \pi_j = 1 \\ \pi_j \geq 0 \end{cases} \quad i, j = 1, 2, 3, 4, 5$$

, 即可得到该马氏链的平稳分布。由样本数据建立CRF模型计算的转移概率矩阵, 我们求解出的平稳分布如表3.5所示。

由于不同消费群体的就餐偏好不同, 在经过无限长时间的转移后, 最终各个就餐地点的平稳分布大致相当。新园食堂和外卖会有超过20%的学生群体选择就餐, 而选择绿叶食堂的学生群体仅有17.4%; 在上财的四个食堂中, 仅有新园食堂的超过了外卖就餐, 而其他三个食堂的学生就餐比例都未能超过外卖就餐。当一所高校的食堂就餐吸引力不如外卖餐饮时, 往往折射出高校食堂后勤

表 3.5: 平稳分布求解结果

因变量	取值	含义	概率值
Y	1	新园食堂	0.221
	2	新食堂	0.199
	3	清真食堂	0.190
	4	绿叶食堂	0.174
	5	外卖	0.216

服务的很多问题，有关部门应立即展开调研，广泛听取各方意见，及时做出整改措施，以更高的标准展现高校的餐饮服务水平。

第四章 总结与展望

4.1 研究总结

4.1.1 本文的创新点

本研究的主要创新有如下几点：

（1）研究视角新颖。针对高校食堂调研问题，本研究未聚焦在主流的满意度调查等研究，也未使用回归分析等较为传统的模型，而是使用了条件随机场模型研究学生群体就餐地点的分布和转移，该模型被广泛应用于自然语言处理领域，而未见于其他领域，因此在研究视角上有所创新。

（2）调研方法贴合实际，数据来源客观，排除了主观因素干扰。本研究以较为坚实的理论基础，结合实际的研究问题，调查方案采用分层抽样和滚雪球抽样，在问卷题目中未设置受访者主观判断的量表类题目，仅统计其就餐地点的客观真实数据，可信度高，真实性得以保证。

（3）调研可拓展性强。可以不断基于近期低频数据更新模型，得到定期更新的估计结果，为高校食堂提升就餐服务动态提供监测依据。

4.1.2 本文的局限

在本研究的实施过程中，由于受到时间因素、个人因素等的影响，还存在如下不足以待改进：

（1）数据量小，调研时间短。本研究的样本选取了约60余位上海财经大学本科生，对于全校几千名师生的总体，本研究的样本选取数据量较小；调研时间为2023年12月的两个星期，时间跨度不够长，且受到季节因素、学生期末考试、考研等社会因素影响，代表性有所欠缺。

（2）忽略了个体异质性，然而在本研究中，问卷数据的相关性检验指出，实际上性别可能会影响就餐地点的选择，是后续可以深入研究的问题。

（3）仅研究个人饮食开销因素对选择就餐地点的影响，忽略其他因素。

（4）未设置转移特征函数，模型过拟合较为严重，数据结构较为简单。

4.2 研究展望

结合本研究的创新点和不足之处，在未来可以深入的研究展望有如下几点：

（1）扩大调研群体，借助高校官方渠道进行调研，得到更为广泛、客观、真实的数据。

（2）对数据结构进行改进，如使用连续型随机变量等。

（3）对模型进行改进。建模时可以考虑CRF的改进模型如引入神经网络等深度学习技术；参数估计方法可以使用IIS等其他不同的方法，交叉验证来选用最优的模型。

（4）对样本进行统计模拟仿真研究，根据样本一次估计的参数结果，生成足够多的模拟样本，重复估计参数直至收敛，可验证条件概率分布列的依概率收敛性质、转移概率矩阵的相合性、马氏链的极限分布等。

参考文献

- Adora, A. & Estepa, V. (2005). Students' perceived service quality and customer satisfaction in a midwestern university foodservice operation.
- Bertomeu-Motos, A., Ezquerro, S., Barios, J. A., et al. (2019). User activity recognition system to improve the performance of environmental control interfaces: a pilot study with patients. *Journal of Neuroengineering and Rehabilitation*, 16(1), 10.
- Biernacki, P. & Waldorf, D. (1981). Snowball sampling: Problems and techniques of chain referral sampling. *Sociological methods & research*, 10(2), 141–163.
- Chen, T., Xu, R., He, Y., et al. (2017). Improving sentiment analysis via sentence type classification using bilstm-crf and cnn. *Expert Systems with Applications*, 72, 221–230.
- Hammersley, J. M. & Clifford, P. (1963). Markov fields on finite graphs and lattices. *Unpublished Manuscript*.
- Klassena, K. J., Trybusb, E., & Kumar, A. (2005). Planning food services for a campus setting. *Hospitality Management*, 24, 579–609.
- Koller, D. & Friedman, N. (2009). *Probabilistic Graphical Models: Principles and Techniques*. MIT press.
- Le, T. A., Arkhipov, M. Y., & Burtsev, M. S. (2017). Application of a hybrid bi-lstm-crf model to the task of russian named entity recognition. In *Conference on Artificial Intelligence and Natural Language* (pp. 91–103).: Springer.
- Lee, H., Hsu, Y., & Kao, H. (2016). Audis: An automatic crf-enhanced disease normalization in biomedical text. <http://doi.org/10.1093/database/baw091>.
- Lee, S. S., Kim, H.-C., et al. (2007). University students' exceptions of brand name foodservices.
- Mozharova, V. A. & Loukachevitch, N. V. (2016). Combining knowledge and crf-based approach to named entity recognition in russian. In *International Conference on Analysis of Images, Social Networks and Texts* (pp. 185–195).: Springer, Cham.
- Na, S. H., Kim, H., Min, J., & et al. (2019). Improving lstm crfs using character-based compositions for korean named entity recognition. *Computer Speech & Language*, 54, 106–121.

- Ng, Y. N. (2005). A study of customer satisfaction, return intention, and word of mouth endorsement in university dining facilities. Master's thesis, Oklahoma State University, Stillwater, Oklahoma, United States. Unpublished master's thesis.
- Nocedal, J. & Wright, S. J. (2006). *Numerical Optimization*. Springer Science & Business Media.
- Qiu, J., Xu, L., Zhai, J., et al. (2017). Extracting causal relations from emergency cases based on conditional random fields. *Procedia Computer Science*, 112, 1623–1632.
- Ross, S. M. (2019). *Introduction to Probability Models*. Academic Press.
- Wei, Q. K., Chen, T., Xu, R. F., et al. (2016). Disease named entity recognition by combining conditional random fields and bidirectional recurrent neural networks. <https://doi.org/10.1093/database/baw140>.
- 丁震 & 朱禹桢 (2020). 高校学生对食堂服务满意度的影响因素研究. 大众标准化, (13), 81–82.
- 余本功 & 范招娣 (2020). 面向自然语言处理的条件随机场模型研究综述. 信息资源管理学报, 10(05), 96–111.
- 冯士雍 (1995). 抽样调查理论与方法. 中国统计出版社.
- 刘全 (2008). 当代高校餐饮服务中心设计探析. Master's thesis, 同济大学.
- 孙平生 (2011). 从价格角度谈高校学生食堂的定位与管理. 华北电力大学学报(社会科学版), (pp. 135–137).
- 孙瑞娜 (2015). 基于crfs的哈萨克语名词短语自动获取. 图书馆理论与实践, (08), 101–105.
- 廖乾超 & 陈文雯 (2019). 高校学生食堂饮食消费特征及影响因素研究——以湖南xx大学为例. 现代经济信息, (28), 164.
- 李航 (2019). 统计学习方法 (第二版). 清华大学出版社.
- 王星 (2014). 非参数统计 (第2版). 清华大学出版社.
- 王照卫 (2022). 基于条件随机场的中文分词方法研究与应用. Master's thesis, 电子科技大学.
- 王红斌, 郜洪奎, 沈强, & 线岩团 (2019). 泰语人名、地名、机构名实体识别研究. 系统仿真学报, 31(05), 1010–1018.
- 白如江, 冷伏海, & 廖君华 (2017). 基于混合内容线索特征的语义组块标注研究. 情报学报, 36(04), 382–391.
- 禚镇宇, 蒋盛益, & 张礼明 (2019). 基于多特征bi-lstm-crf的影评人名识别研究. 中文信息学报, 33(3), 94–101.

- 茆诗松, 程依明, & 濮晓龙 (2019). 概率论与数理统计教程. 高等教育出版社.
- 袁里驰 (2023). 基于bilstm-crf的中文分词和词性标注联合方法. 中南大学学报(自然科学版), 54(08), 3145–3153.
- 高庆 (2009). 公共服务满意度影响因素的统计分析——以高校学生食堂为例. 软科学, 23(02), 80–84+89.

附 录

上海财经大学学生就餐调查问卷

您好！我们正在进行一项对上海财经大学学生的就餐调查，感谢您参与问卷调研！我们将严格承诺，我们将对您的个人信息严格保密，本问卷收集的数据将仅用于学术研究，感谢您的参与！

1. 您的性别是？

(1) 男 (2) 女

2. 您的年级是？

(1) 大一 (2) 大二 (3) 大三 (4) 大四 (5) 硕博生

3. 您来自的学院是？

(1) 会计学院 (2) 金融学院 (3) 商学院 (4) 经济学院
(5) 公共经济与管理学院 (6) 统计与管理学院 (7) 信息管理与工程学院
(8) 法学院 (9) 人文学院 (10) 外国语学院 (11) 数学学院 (12) 其他

4. 您最近一次就餐（早、午、晚餐）的地点是？

(1) 新园食堂 (2) 新食堂 (3) 清真食堂
(4) 绿叶食堂 (5) 外卖 (6) 未就餐

5. 您选择该地点的原因是？

(1) 就餐方便 (2) 就餐环境好 (3) 饭菜卫生
(4) 饭菜较为可口 (5) 饭菜价格实惠

6. 您每日饮食开销约为？

(1) 30元及以下 (2) 30-60元 (3) 60元及以上

致 谢

窗间过马，流年不居，四载春秋，一朝如驰。曾无数次想象写到这一页时的情形，但真正落笔于此刻，之前许诺过的相见于致谢、构思过的万千言辞，却统统略显苍白，终不如感念读者垂阅，祝颂一切皆安。

在这凝结了我四番寒暑的最后一页，我想要致谢于在我生命中起到至关重要、不可替代作用的所有人，无论他们是父母师长，亦或同窗挚友，甚至匆匆路人。我满怀致意，便汇作之前那句：铭心镂骨，结草衔环。

行文至此，落笔为终。我回想起高中时读到的一句诗：“已识乾坤大，犹怜草木青。”初见时未解其意，只觉作者胸襟辽阔，人生豁达。如今我不知道是否参透这句五言，但愿为它稍作改动，以作收束弱冠之年的题眼：

愿识乾坤大，亦怜草木青。